



Université Sidi Mohamed Ben Abdellah

Faculté des Sciences Dhar El Mahraz – Fès

Département d'Informatique

Master : Big Data & Systèmes Intelligents

Air Quality Prediction in Moroccan Cities

Mini Projet Data Science

Réalisé par :

KHALLABI Bilal

S136126026

Année universitaire : 2025/2026

Table des matières

1	Introduction	3
2	Objectifs du projet	4
3	Collecte des données	5
3.1	Données météorologiques collectées	5
3.2	Données de pollution collectées	5
4	Préparation des données	7
4.1	Chargement des données	7
4.2	Vérification des valeurs manquantes	7
4.3	Suppression des doublons	7
4.4	Conversion des types	7
4.5	Création de variables temporelles	8
4.6	Encodage des variables catégorielles	8
4.7	Normalisation	8
5	Modèles de machine learning	9
5.1	Régression linéaire	9
5.2	Arbre de décision	9
5.3	Random Forest	9
6	Évaluation des modèles	10
6.1	MAE	10
6.2	RMSE	10
6.3	Score R^2	10
7	Résultats obtenus	11
8	Simulation de l'apprentissage fédéré	12
8.1	Répartition des clients	12

8.2	Principe de FedAvg	12
9	Comparaison entre modèle centralisé et modèle fédéré	14
9.1	Résultats de comparaison	14
9.2	Interprétation	14
10	Organisation du projet	16
10.1	Fichiers de données	16
10.2	Scripts Python	16
10.3	Fichiers de résultats	16
11	Conclusion	17

Chapitre 1

Introduction

La qualité de l'air est un élément important pour la santé publique et pour la protection de l'environnement. Dans les grandes villes, la pollution atmosphérique peut être influencée par plusieurs facteurs comme le trafic routier, les activités industrielles, la température, l'humidité, la pression atmosphérique et la vitesse du vent.

Dans ce mini projet, nous avons réalisé un système de prédiction de la qualité de l'air dans plusieurs villes marocaines. Le projet se base sur des données réelles collectées à partir de l'API OpenWeatherMap. Les données collectées contiennent à la fois des informations météorologiques et des informations sur les polluants atmosphériques.

L'objectif principal est de prédire la concentration de PM2.5 à partir des variables météorologiques et environnementales. Pour cela, nous avons utilisé plusieurs modèles de régression, puis nous avons comparé leurs performances à l'aide de métriques classiques comme MAE, RMSE et le score R^2 .

Une partie bonus a aussi été réalisée. Elle consiste à simuler un apprentissage fédéré, où chaque ville est considérée comme un client local. Cette approche permet de comprendre le principe de l'apprentissage distribué sans centraliser directement toutes les données.

Chapitre 2

Objectifs du projet

Les objectifs de ce projet sont les suivants :

- Collecter des données réelles sur la météo et la pollution de l'air.
- Stocker les données dans un fichier CSV structuré.
- Nettoyer les données et supprimer les doublons.
- Traiter les valeurs manquantes.
- Encoder les variables catégorielles.
- Normaliser les variables numériques.
- Construire plusieurs modèles de machine learning.
- Prédire la concentration de PM2.5.
- Évaluer les performances des modèles.
- Simuler un apprentissage fédéré simple avec FedAvg.
- Comparer l'apprentissage centralisé et l'apprentissage fédéré.

Chapitre 3

Collecte des données

La première étape du projet consiste à collecter les données à partir de l'API OpenWeatherMap. Cette API permet d'obtenir des données météorologiques et des données de pollution atmosphérique pour différentes villes.

Les villes utilisées dans ce projet sont :

- Casablanca
- Rabat
- Marrakech
- Fès

Pour chaque ville, le script de collecte récupère les données météorologiques et les données de pollution. Les données sont ensuite sauvegardées dans un fichier CSV.

3.1 Données météorologiques collectées

Les variables météorologiques collectées sont :

- Température
- Température ressentie
- Humidité
- Pression atmosphérique
- Vitesse du vent
- Direction du vent
- Couverture nuageuse
- Description météorologique

3.2 Données de pollution collectées

Les données de pollution collectées sont :

- AQI : Air Quality Index
- CO
- NO
- NO2

- O3
- SO2
- PM2.5
- PM10
- NH3

Le fichier généré après la collecte est :

`morocco_air_quality_data.csv`

Après l'exécution du script, le dataset contient 813 lignes et 23 colonnes.

Chapitre 4

Préparation des données

Après la collecte, les données brutes doivent être préparées avant d'être utilisées par les modèles de machine learning. Cette étape est très importante, car la qualité des données influence directement la qualité des prédictions.

4.1 Chargement des données

Les données sont chargées à partir du fichier :

```
morocco_air_quality_data.csv
```

Le dataset initial contient :

- 813 lignes
- 23 colonnes

4.2 Vérification des valeurs manquantes

Une vérification des valeurs manquantes a été effectuée. D'après les résultats obtenus, aucune colonne ne contient de valeur manquante dans le dataset utilisé.

4.3 Suppression des doublons

Le script supprime d'abord les doublons exacts. Ensuite, il supprime les doublons logiques en gardant une seule ligne pour chaque combinaison ville et heure.

Dans notre cas, le nombre de doublons exacts détectés est égal à 0.

4.4 Conversion des types

Les colonnes de date sont converties au format datetime. Les colonnes numériques sont aussi converties correctement afin d'éviter les erreurs pendant l'entraînement des modèles.

Les colonnes numériques comprennent par exemple :

- temperature

- humidity
- pressure
- wind_speed
- aqi
- co
- no2
- o3
- pm2_5
- pm10

4.5 Création de variables temporelles

À partir de la colonne timestamp, nous avons ajouté des variables temporelles :

- year
- month
- day
- hour

Ces variables peuvent aider le modèle à apprendre les variations de la pollution selon le temps.

4.6 Encodage des variables catégorielles

Les variables catégorielles comme la ville et la description météo sont transformées avec un encodage one-hot. Cela permet aux modèles de machine learning d'utiliser ces informations sous forme numérique.

4.7 Normalisation

Les variables numériques sont normalisées avec StandardScaler. Cette étape est particulièrement utile pour la régression linéaire, car elle permet de mettre les variables sur une échelle comparable.

Après la préparation, deux fichiers sont générés :

```
morocco_air_quality_data_clean.csv
```

```
morocco_air_quality_data_model_ready.csv
```

Le dataset final prêt pour le machine learning contient 813 lignes et 39 colonnes.

Chapitre 5

Modèles de machine learning

Dans ce projet, nous avons choisi de prédire la concentration de PM2.5. Il s'agit donc d'un problème de régression.

La variable cible est :

pm2_5

Les données sont divisées en deux parties :

- 80% pour l'entraînement
- 20% pour le test

Après la division, nous obtenons :

- 650 exemples pour l'entraînement
- 163 exemples pour le test

5.1 Régression linéaire

La régression linéaire est un modèle simple qui cherche à établir une relation linéaire entre les variables d'entrée et la variable cible. Elle est utilisée comme modèle de base.

5.2 Arbre de décision

L'arbre de décision est un modèle capable de capturer des relations non linéaires. Il divise les données selon plusieurs règles de décision.

5.3 Random Forest

Le Random Forest est un modèle basé sur plusieurs arbres de décision. Il permet souvent d'obtenir de meilleurs résultats qu'un seul arbre, car il réduit le surapprentissage.

Chapitre 6

Évaluation des modèles

Les modèles sont évalués à l'aide de trois métriques principales.

6.1 MAE

La MAE, ou Mean Absolute Error, mesure l'erreur absolue moyenne entre les valeurs réelles et les valeurs prédites.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Une valeur faible de MAE indique que le modèle fait peu d'erreurs en moyenne.

6.2 RMSE

La RMSE, ou Root Mean Squared Error, mesure la racine carrée de l'erreur quadratique moyenne.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Cette métrique donne plus d'importance aux grandes erreurs.

6.3 Score R^2

Le score R^2 mesure la capacité du modèle à expliquer la variation de la variable cible.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Une valeur proche de 1 indique un bon modèle.

Chapitre 7

Résultats obtenus

Les résultats obtenus pour les trois modèles sont présentés dans le tableau suivant.

TABLE 7.1 – Résultats des modèles de régression

Modèle	MAE	RMSE	R ²
Régression linéaire	0.8265	1.1311	0.8895
Arbre de décision	0.5921	1.3878	0.8336
Random Forest	0.5549	1.1579	0.8842

D’après les résultats, la régression linéaire obtient le meilleur score R^2 avec une valeur de 0.8895 et la plus faible RMSE avec une valeur de 1.1311. Cela signifie qu’elle explique bien la variation de la concentration PM2.5 dans ce dataset.

Le Random Forest obtient la meilleure MAE avec une valeur de 0.5549, ce qui signifie qu’il fait moins d’erreurs moyennes absolues. Cependant, sa RMSE est légèrement supérieure à celle de la régression linéaire.

L’arbre de décision donne des résultats corrects, mais il possède la RMSE la plus élevée et le score R^2 le plus faible parmi les trois modèles.

Ainsi, le meilleur modèle global dans cette expérience est la régression linéaire, car elle offre le meilleur équilibre entre RMSE et R^2 .

Chapitre 8

Simulation de l'apprentissage fédéré

L'apprentissage fédéré est une approche de machine learning dans laquelle les données restent localement chez les clients. Au lieu de regrouper toutes les données dans un seul serveur central, chaque client entraîne un modèle local sur ses propres données.

Dans notre projet, chaque ville représente un client fédéré :

- Client 1 : Casablanca
- Client 2 : Fès
- Client 3 : Marrakech
- Client 4 : Rabat

8.1 Répartition des clients

Après la division des données, la répartition des clients dans l'ensemble d'entraînement est la suivante :

TABLE 8.1 – Répartition des données par client

Ville	Nombre d'échantillons
Casablanca	163
Fès	163
Marrakech	162
Rabat	162

Cette répartition est équilibrée, car chaque ville possède presque le même nombre d'échantillons.

8.2 Principe de FedAvg

La méthode utilisée est FedAvg, c'est-à-dire Federated Averaging. Le principe est le suivant :

1. Chaque client entraîne un modèle local sur ses données.
2. Chaque client envoie les paramètres appris.

3. Le serveur agrège les paramètres.
4. L'agrégation est faite par moyenne pondérée selon le nombre d'échantillons.

La formule générale est :

$$w_{global} = \sum_{k=1}^K \frac{n_k}{n} w_k$$

avec :

- K : nombre de clients.
- n_k : nombre d'échantillons du client k .
- n : nombre total d'échantillons.
- w_k : paramètres locaux du client k .
- w_{global} : paramètres du modèle global.

Dans notre simulation, nous avons utilisé 5 rounds fédérés. À chaque round, chaque ville entraîne une régression linéaire locale, puis les coefficients et l'intercept sont agrégés.

Chapitre 9

Comparaison entre modèle centralisé et modèle fédéré

Dans l'apprentissage centralisé, toutes les données sont regroupées dans un seul dataset, puis un seul modèle est entraîné.

Dans l'apprentissage fédéré, les données restent séparées par ville. Chaque ville entraîne un modèle local, puis les paramètres sont agrégés pour construire un modèle global.

9.1 Résultats de comparaison

Les résultats obtenus sont présentés dans le tableau suivant :

TABLE 9.1 – Comparaison entre apprentissage centralisé et apprentissage fédéré

Approche	MAE	RMSE	R ²
Régression linéaire centralisée	0.8534	1.1531	0.8238
Régression linéaire fédérée avec FedAvg	2.2866	2.9119	-0.1237

Les résultats montrent que le modèle centralisé donne de meilleures performances que le modèle fédéré simulé. Le modèle centralisé obtient une MAE de 0.8534, une RMSE de 1.1531 et un score R² de 0.8238.

Le modèle fédéré obtient une MAE plus élevée, une RMSE plus élevée et un score R² négatif. Cela indique que le modèle fédéré simulé n'arrive pas à bien généraliser sur les données de test.

9.2 Interprétation

La différence de performance peut s'expliquer par le fait que la simulation fédérée utilise une agrégation simple des coefficients de régression linéaire. Cette méthode est pédagogique, mais elle reste limitée.

Dans une vraie approche fédérée, le modèle global est envoyé aux clients à chaque round, puis chaque client continue l'entraînement à partir du modèle global. Dans notre cas, avec `sklearn LinearRegression`, il n'est pas possible d'initialiser directement le

modèle avec les coefficients globaux avant l'entraînement. La simulation reste donc une approximation simple de FedAvg.

Malgré cette limite, cette partie est intéressante car elle montre le principe général de l'apprentissage fédéré et la différence entre une approche centralisée et une approche distribuée.

Chapitre 10

Organisation du projet

Le projet contient plusieurs fichiers importants.

10.1 Fichiers de données

- `morocco_air_quality_data.csv` : données brutes collectées.
- `morocco_air_quality_data_clean.csv` : données nettoyées.
- `morocco_air_quality_data_model_ready.csv` : données prêtes pour le machine learning.

10.2 Scripts Python

- `scaping.py` : collecte des données.
- `Step 2 Prepare the data.py` : préparation des données.
- `Step 3 Build the model.py` : entraînement et évaluation des modèles.
- `Simulate federated learning.py` : simulation de l'apprentissage fédéré.

10.3 Fichiers de résultats

- `step3_model_results.csv` : résultats des modèles de régression.
- `federated_vs_centralized_results.csv` : comparaison entre modèle centralisé et modèle fédéré.

Chapitre 11

Conclusion

Dans ce mini projet, nous avons réalisé un système de prédiction de la qualité de l'air dans plusieurs villes marocaines. Nous avons commencé par collecter des données réelles à partir de l'API OpenWeatherMap. Ensuite, nous avons nettoyé et préparé les données afin de les utiliser dans des modèles de machine learning.

Le dataset final contient 813 observations. Après la préparation, les données ont été utilisées pour prédire la concentration de PM2.5. Trois modèles de régression ont été testés : la régression linéaire, l'arbre de décision et le Random Forest.

Les résultats montrent que la régression linéaire donne le meilleur score R^2 et la meilleure RMSE. Le Random Forest donne la meilleure MAE. Ces résultats indiquent que les modèles arrivent à prédire correctement la concentration de PM2.5 à partir des variables disponibles.

Nous avons aussi réalisé une simulation d'apprentissage fédéré. Chaque ville a été considérée comme un client local. Les résultats montrent que le modèle centralisé est plus performant que le modèle fédéré simulé. Cependant, cette simulation permet de comprendre le fonctionnement général de FedAvg et l'intérêt de l'apprentissage fédéré dans les scénarios où les données doivent rester distribuées.

Comme amélioration future, il serait possible de collecter plus de données sur une période plus longue, d'ajouter d'autres villes marocaines, d'utiliser des modèles plus avancés, et de développer une interface web pour visualiser les résultats et les prédictions.